

Aprendizaje Supervisado Aplicado al Desafío del Titanic

Sebastián Andres Ulloa Quezada, Universidad Bernardo O'Higgins

Docente: Enrique Gonzalo Pastene Aceituno

RESUMEN

Este trabajo realiza un análisis de supervivencia del caso Titanic con el objetivo de predecir la supervivencia de los pasajeros utilizando técnicas de Machine Learning. A través de una etapa de exploración univariada y bivariada, se identificaron patrones relevantes asociados a la supervivencia, como el género, la clase del pasajero y el tamaño del grupo familiar. Posteriormente, se aplicaron técnicas de preprocesamiento, tratamiento de valores atípicos y codificación de variables, seguidas de la evaluación comparativa de varios modelos de clasificación mediante validación cruzada y búsqueda de hiperparámetros con GridSearchCV. Finalmente, se generaron predicciones sobre el conjunto de test, se analizaron las tasas de supervivencia estimadas y se visualizaron los resultados, proporcionando una interpretación clara y visual del comportamiento del modelo.

INTRODUCCIÓN

Objetivo y relevancia del problema

El problema abordado consiste en predecir la probabilidad de supervivencia de los pasajeros del Titanic a partir de información disponible como el sexo, la edad, la clase del ticket, el número de acompañantes, el puerto de embarque, entre otras variables. Se trata de un problema clásico de clasificación binaria, donde el objetivo es estimar si un pasajero sobrevivió (1) o no (0) al hundimiento del Titanic.

Esta tarea implica aplicar técnicas de análisis exploratorio, preprocesamiento de datos y modelos de aprendizaje supervisado, con el fin de construir un clasificador que generalice bien sobre datos desconocidos, como los del conjunto de test provisto. Además de lograr buenas métricas de desempeño, el proyecto busca interpretar y visualizar los factores más relevantes asociados a la supervivencia.

Descripción del Dataset

El conjunto de datos utilizado corresponde al desafío del Titanic, provisto por la plataforma Kaggle. Este dataset contiene información sobre 891 pasajeros del Titanic en el archivo train.csv, incluyendo variables como el nombre, sexo, edad, clase del ticket, número de familiares a bordo, tarifa pagada, número de cabina, puerto de embarque además de una variable target que representa si el pasajero sobrevivió (Survived = 1) o no (Survived = 0).

El dataset test.csv contiene los mismos campos (excepto la variable objetivo Survived) y se utiliza para generar las predicciones finales.

El objetivo es utilizar las variables disponibles para entrenar un modelo que prediga correctamente el estado de supervivencia en el conjunto de test. Las variables se muestran en la Tabla 1.

TABLA 1: SET DE VARIABLES CONTENIDAS EN EL PROBLEMA

Variable	Tipo de dato	Descripción
PassengerId	Entero	Identificador único del pasajero
Survived	Binaria (0 = No, 1 = Sí)	Variable objetivo: indica si el pasajero sobrevivió
Pclass	Ordinal (1, 2, 3)	Clase del pasajero (1ª = alta, 3ª = baja)
Name	Texto	Nombre completo del pasajero
Sex	Categórica	Sexo del pasajero (male, female)
Age	Numérica (continua)	Edad del pasajero en años
SibSp	Numérica (entera)	Número de hermanos o esposos a bordo
Parch	Numérica (entera)	Número de padres o hijos a bordo
Ticket	Texto (alfanumérico)	Número de ticket del pasajero
Fare	Numérica (continua)	Tarifa pagada por el ticket
Cabin	Categórica (texto)	Número de cabina asignada (muchos valores faltantes)
Embarked	Categórica (C, Q, S)	Puerto de embarque: Cherbourg, Queenstown, Southampton

ANÁLISIS EXPLORATORIO DE DATOS (EDA)

Análisis Univariado

El análisis univariado tuvo como objetivo explorar la distribución de cada variable de forma individual, permitiendo entender su comportamiento. En las variables categóricas, como Sex, Embarked y Pclass, se analizaron las frecuencias de cada categoría mediante gráficos de barras (countplot), revelando por ejemplo que la mayoría de los pasajeros eran hombres y que la mayor parte embarcó desde Southampton.

También se observó que la clase 3 (Pclass = 3) tenía la mayor cantidad de pasajeros, lo cual tiene implicancias en la distribución de supervivencia posterior.




Figura 1: Gráficos de barra variables categóricas

En cuanto a las variables numéricas como Age, Fare, SibSp y Parch, se usaron histogramas y boxplots para analizar su distribución y detectar posibles valores atípicos. Se observó que la edad tiene una distribución ligeramente sesgada hacia la izquierda, con una concentración de pasajeros jóvenes, mientras que Fare presenta una fuerte asimetría a la derecha, indicando la presencia de tarifas inusualmente altas. La variable objetivo Survived muestra un claro desbalance de clases, con una mayoría de pasajeros que no sobrevivieron, lo que implica que los modelos de clasificación deben considerar este desequilibrio para no sesgarse hacia la clase mayoritaria.

En cuanto a la variable Pclass, se detecta una concentración significativa de pasajeros en la tercera clase, lo cual está relacionado con diferencias socioeconómicas que podrían influir directamente en las posibilidades de supervivencia. Por otro lado, la variable Age presenta una distribución asimétrica con mayor frecuencia de pasajeros entre los 20 y 30 años, y la presencia de algunos valores extremos que podrían afectar la sensibilidad de ciertos algoritmos.

Las variables SibSp y Parch, que representan la cantidad de familiares a bordo, muestran distribuciones con picos marcados en cero, lo que indica que la mayoría de los pasajeros viajaban solos o con un único acompañante. Sin embargo, también presentan valores atípicos que corresponden a familias más numerosas.

La variable Fare (tarifa pagada) evidencia una fuerte asimetría positiva, con la mayoría de los pasajeros pagando tarifas bajas y algunos pocos pagando valores muy elevados, lo que genera una alta dispersión visible en el boxplot. Este comportamiento sugiere la necesidad de transformar o escalar dicha variable para mejorar la estabilidad de los modelos predictivos.




Figura 2: Gráficos de barra variables numéricas

Análisis Bivariado

El análisis bivariado permitió estudiar la relación entre las variables independientes y la variable objetivo Survived, con el fin de identificar patrones relevantes para la predicción. Se observó una fuerte asociación entre el sexo y la supervivencia, destacando que una mayor proporción de mujeres sobrevivió en comparación con los hombres.

De igual manera, los pasajeros de primera clase (Pclass = 1) mostraron una tasa de supervivencia considerablemente más alta que los de clases inferiores, lo que refleja desigualdades en el acceso a los botes salvavidas. También se utilizaron boxplots para comparar variables numéricas como Age y Fare respecto al estado de supervivencia, evidenciando que los sobrevivientes tendían a ser más jóvenes y haber pagado tarifas más altas. Por último, las combinaciones de variables categóricas como Sex y Embarked también ofrecieron información útil al mostrar diferencias notables en la proporción de supervivencia según el puerto de embarque.




Figura 3: Gráficos de supervivencia por variable




Figura 4: Mapa de Correlacion entre variables

La matriz de correlación revela que las variables más asociadas a la supervivencia son Sex (-0.54), Pclass (-0.34) y Fare (0.26), lo que indica que las mujeres, los pasajeros de clases altas y quienes pagaron tarifas más elevadas tuvieron mayor probabilidad de sobrevivir. También se observa una alta correlación entre SibSp, Parch y FamilySize, debido a que esta última combina ambas, lo cual es importante considerar para evitar redundancia en el modelado. La variable IsAlone, derivada de FamilySize, presenta una correlación negativa con la supervivencia (-0.20), lo que sugiere que viajar solo reducía las probabilidades de sobrevivir. Aunque variables como Age y Embarked muestran baja correlación directa con la variable objetivo, podrían ser relevantes en combinación con otras variables o mediante transformaciones específicas.

PREPROCESAMIENTO DE DATOS

Las variables Age, Fare y Embarked contenían datos nulos, los cuales fueron imputados utilizando la mediana o la moda según el caso. La variable Cabin, al presentar una gran cantidad de valores ausentes, fue descartada por su escasa utilidad directa en el modelo. También se estandarizó el formato de las variables categóricas y se verificó la integridad general del conjunto de datos. Posteriormente, se aplicó ingeniería de características para enriquecer el dataset.

Se creó la variable FamilySize como la suma de SibSp y Parch más uno, representando el total de miembros del grupo familiar a bordo. A partir de esta, se generó la variable IsAlone, que indica si un pasajero viajaba solo. Además, se extrajeron prefijos del número de ticket (TicketPrefix) para capturar posibles patrones ligados al tipo de pasaje. Las variables categóricas como Sex y Embarked fueron codificadas numéricamente mediante LabelEncoder.

Finalmente, se detectaron y trataron valores atípicos en variables numéricas como Fare, Age, SibSp y Parch, utilizando el método del rango intercuartílico (IQR), aplicando “clipping” para mantener la estructura del conjunto de datos sin eliminar registros. Para asegurar que todas las variables numéricas tuvieran una escala comparable, se aplicó StandardScaler antes del entrenamiento de los modelos.

SELECCIÓN Y EVALUACIÓN DE MODELOS

El conjunto de entrenamiento fue dividido en una partición de entrenamiento (80%) y validación (20%) utilizando train_test_split, asegurando una separación adecuada entre los datos para entrenamiento del modelo y evaluación de su capacidad de generalización. Además, se aplicó validación cruzada durante la búsqueda de hiperparámetros para mejorar la robustez de la evaluación.

Se seleccionaron cuatro modelos de clasificación supervisada: Random Forest, Support Vector Machine (SVM), K-Nearest Neighbors (KNN) y Gradient Boosting. Las métricas utilizadas para evaluar su rendimiento incluyeron accuracy, precisión, recall y F1-score, además de validar la estabilidad mediante el promedio y desviación estándar de la validación cruzada.

Para cada modelo se implementó GridSearchCV, explorando combinaciones de hiperparámetros relevantes (como n_estimators, max_depth, C, gamma, n_neighbors, etc.) con validación cruzada de 5 pliegues. Este proceso permitió identificar la configuración óptima de cada modelo, maximizando el rendimiento en validación.

Los modelos fueron comparados en una tabla resumen que incluía todas las métricas mencionadas, junto al tiempo de entrenamiento y el desempeño en el conjunto de validación. Gradient Boosting y Random Forest destacaron por su buen equilibrio entre precisión y capacidad de generalización, siendo seleccionados para realizar las predicciones finales sobre el conjunto de test.

TABLA 2: RESULTADOS MODELOS Y BÚSQUEDA EN GRILLA

Modelo	CV Accuracy	Test Accuracy	Parametros
KNN	0,793	0,837	{'n_neighbors': 5, 'weights': 'uniform'}
SVM	0,822	0,815	{'C': 1, 'gamma': 'auto', 'kernel': 'rbf'}
Random Forest	0,832	0,810	{'max_depth': 5, 'min_samples_split': 2, 'n_estimators': 200}
Gradient Boosting	0,828	0,810	{'learning_rate': 0.05, 'max_depth': 3, 'n_estimators': 100}

RESULTADOS SOBRE CONJUNTO DE TEST




Figura 5: Gráficos de supervivencia por variable conjunto de test

A partir de las predicciones realizadas sobre el conjunto de test, se obtuvo una tasa de supervivencia estimada del 32.30%, lo cual está en línea con las proporciones reales observadas históricamente en el naufragio del Titanic.

Del total de pasajeros en el test, 283 fueron clasificados como no sobrevivientes y 135 como sobrevivientes. Este desbalance en las predicciones refleja una fuerte tendencia del modelo a identificar correctamente la clase mayoritaria, manteniendo sin embargo una proporción razonable de sobrevivientes detectados.

TABLA 3: RESULTADOS SUPERVIVIENTES POR SEXO

Sexo	No Superviviente	Superviviente
Femenino	0,17	0,83
Masculino	0,97	0,03

TABLA 4: RESULTADOS SUPERVIVIENTES POR CLASE

Clase	No Superviviente	Superviviente
1	0,51	0,49
2	0,66	0,34
3	0,77	0,23

TABLA 5: RESULTADOS SUPERVIVIENTES POR EMBARQUE

Clase	No Superviviente	Superviviente
Southampton	0,57	0,43
Cherbourg	0,50	0,50
Queenstown	0,75	0,25

TABLA 6: RESULTADOS SUPERVIVIENTES POR IS_ALONE

Clase	No Superviviente	Superviviente
0	0,50	0,50
1	0,79	0,21

Al analizar la supervivencia predicha por género, se observa un comportamiento claramente diferenciado: el 83% de las mujeres fueron clasificadas como sobrevivientes, mientras que el 97% de los hombres fueron clasificados como no sobrevivientes. Gráficamente, también se evidencian diferencias por clase (Pclass), puerto de embarque (Embarked) y composición familiar (SibSp, Parch), donde los grupos familiares pequeños y pasajeros en clases altas presentan una mayor tasa de supervivencia predicha.




Figura 6: Gráficos distribución probabilidad para conjunto test

A partir de los gráficos de densidad por variable numérica según las predicciones de supervivencia, se puede concluir que la variable Age muestra que los pasajeros predichos como sobrevivientes tienden a concentrarse en edades más jóvenes, especialmente entre los 15 y 35 años, mientras que los no sobrevivientes presentan una distribución más amplia.

En cuanto a Fare, los sobrevivientes se agrupan en valores más altos de tarifa, lo cual sugiere que el modelo asoció tarifas más costosas con una mayor probabilidad de supervivencia, posiblemente por estar vinculadas a clases más altas. Para SibSp y Parch, se observa que quienes viajaban con uno o dos acompañantes tienen mayor densidad de predicciones positivas, en contraste con quienes viajaban solos o con grupos muy grandes, que tienden a ser clasificados como no sobrevivientes.

Finalmente, la variable FamilySize, que combina SibSp y Parch, refuerza esa tendencia: la mayor probabilidad de supervivencia predicha se da en pasajeros con tamaño familiar pequeño (2 a 4 personas), mientras que los que viajaban solos (FamilySize = 1) o en familias numerosas presentan mayor densidad entre los no sobrevivientes. Estas observaciones coinciden con los patrones históricos del Titanic y demuestran que el modelo logró captar relaciones significativas entre las características numéricas y la supervivencia.

CONCLUSIONES

El presente trabajo permitió abordar de forma integral un problema clásico de clasificación binaria aplicando técnicas de ciencia de datos y aprendizaje automático. A partir de un análisis exploratorio detallado, se identificaron variables clave que influyen significativamente en la probabilidad de supervivencia, como el sexo, la clase del pasaje y el tamaño del grupo familiar. Estos hallazgos sirvieron de base para la construcción de nuevas variables y la selección de características relevantes.

Durante la fase de modelado, se compararon distintos algoritmos supervisados, destacándose Gradient Boosting y Random Forest como los modelos con mejor desempeño en términos de precisión, recall y estabilidad de la validación cruzada. La aplicación de técnicas de búsqueda de hiperparámetros y normalización de datos permitió optimizar el rendimiento de los modelos y mejorar su capacidad de generalización.

Finalmente, las predicciones sobre el conjunto de test mostraron resultados coherentes con los patrones observados en el conjunto de entrenamiento. El análisis de tasas de supervivencia y las visualizaciones generadas permitieron validar la utilidad del modelo tanto desde una perspectiva predictiva como interpretativa. Este proyecto demuestra cómo un enfoque sistemático de análisis de datos puede generar modelos robustos y útiles para la toma de decisiones basada en datos.

BIBLIOGRAFÍA

1. Géron, A. (2019). **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems** (2nd ed.). O'Reilly Media.
2. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). **Scikit-learn: Machine learning in Python**. **Journal of Machine Learning Research**, 12, 2825-2830. <https://jmlr.org/papers/v12/pedregosa11a.html>
3. Waskom, M. (2021). **Seaborn: statistical data visualization**. **Journal of Open Source Software**, 6(60), 3021. <https://doi.org/10.21105/joss.03021>
4. Kaggle. (n.d.). **Titanic - Machine Learning from Disaster**. Kaggle. <https://www.kaggle.com/c/titanic>
5. VanderPlas, J. (2016). **Python Data Science Handbook: Essential Tools for Working with Data**. O'Reilly Media.