

Aprendizaje no supervisado aplicado a segmentación de clientes

Sebastián Andrés Ulloa Quezada, Universidad Bernardo O'Higgins
Docente: Enrique Gonzalo Pastene Aceituno

RESUMEN

El presente estudio exploró la segmentación de clientes mediante el uso combinado de técnicas de reducción de dimensionalidad (t-SNE) y algoritmos de clustering (KMeans y DBSCAN). La visualización resultante permitió identificar perfiles distintos, donde KMeans reveló grupos principales y DBSCAN destacó segmentos especializados y outliers.

INTRODUCCION

Objetivo y relevancia del problema

En el contexto comercial, comprender el comportamiento y las características de los clientes se hace necesario para diseñar estrategias efectivas de fidelización y marketing personalizado. Este análisis tiene como objetivo general generar una segmentación de clientes basada en características demográficas y patrones de consumo, permitiendo identificar perfiles homogéneos dentro del conjunto de consumidores del centro comercial.

Ademas se busca comparar distintas metodologías de clustering K-Means y DBSCAN para evaluar su desempeño en la identificación de patrones significativos dentro del conjunto de datos.

Descripción del dataset

El conjunto de datos utilizado contiene información demográfica y de comportamiento de compra de 200 clientes de un centro comercial. Las variables registradas permiten explorar patrones en función del género, la edad, el nivel de ingresos y una métrica de comportamiento de gasto definida por el centro comercial. Las variables incluidas en el dataset se muestran en la Tabla 1.

TABLA 1: SET DE VARIABLES CONTENIDAS EN EL PROBLEMA

Variable	Descripción
CustomerID	Identificador único para cada cliente.
Gender	Genero del cliente
Age	Edad del cliente en años.
Annual Income (k\$)	Ingreso anual del cliente en miles de dolares.
Spending Score (1-100)	Puntuación del centro comercial que mide el nivel de gasto del cliente.

ANÁLISIS EXPLORATORIO DE DATOS (EDA)

Análisis Univariado

El análisis univariado tuvo como objetivo explorar la distribución de cada variable de forma individual, permitiendo entender su comportamiento y su potencial contribución a la segmentación. En el caso de la variable categórica Gender, se analizaron las frecuencias de cada categoría mediante gráficos de barras, revelando una distribución relativamente balanceada entre hombres y mujeres, con una ligera mayoría de clientas.

Para las variables numéricas (Age, Annual Income (k\$) y Spending Score (1-100)), se utilizaron histogramas y gráficos de densidad. Se observó que la edad tiene una distribución con mayor concentración entre los 30 y 40 años, mientras que el ingreso anual presenta una dispersión bastante uniforme entre los distintos rangos. Por su parte, la puntuación de gasto mostró una distribución más irregular, con presencia de grupos de clientes tanto con puntajes bajos como altos, lo cual sugiere comportamientos de consumo diferenciados y potencialmente útiles para la segmentación tabla 2.

TABLA 2: DESCRIPTIVO DE VARIABLES

	Age	Annual Income (k\$)	Spending Score (1-100)
count	200	200	200
mean	38.85	60.56	50.2
std	13.96	26.26	25.82
min	18	15	1
25%	28.75	41.5	34.75
50%	36	61.5	50
75%	49	78	73
max	70	137	99

En la tabla descriptiva, podemos concluir que la muestra analizada presenta una distribución diversa en cuanto a edad e ingresos anuales, lo que sugiere una diversidad socio económica. Si bien el puntaje de gasto promedio se sitúa alrededor de 50, la amplia desviación estándar indica que existen individuos con patrones de consumo significativamente diferentes, desde gastadores muy conservadores hasta otros más propensos al gasto. Esta variabilidad en los puntajes de gasto podría estar relacionada con factores como la edad o los ingresos, aunque sería necesario un análisis más profundo para confirmar estas posibles correlaciones.




Figura 1 : Gráficos univariados variables incluidas en el problema

En la figura 1 se observa que hay una mayor presencia de mujeres en la data, representando aproximadamente el doble de clientes femeninos en comparación con hombres. La edad de los clientes se distribuye de manera relativamente uniforme a lo largo del rango observado, aunque con una concentración entre los 20 y 40 años. En cuanto a los ingresos anuales, la distribución es asimétrica positiva, indicando que la mayoría de los clientes tienen ingresos más bajos, con un pico alrededor de 50k y una cola hacia los ingresos más altos, lo que sugiere una base de clientes con una amplia gama de niveles económicos.

Análisis Bivariado

El gráfico muestra la relación entre los ingresos anuales y la puntuación de gasto, diferenciando por género. Se observa una dispersión significativa en ambos grupos a lo largo del rango de ingresos y puntuaciones de gasto. No se aprecia una diferencia clara o consistente en el patrón de gasto entre hombres y mujeres; ambos grupos muestran una amplia variedad de comportamientos de consumo en relación con sus ingresos.




Figura 2 : Gráfico de dispersión segmentado por genero

La matriz de correlación revela que existe una correlación negativa moderada entre la edad y la puntuación de gasto, sugiriendo una tendencia a que las personas más jóvenes tengan puntajes de gasto ligeramente más altos. Por el contrario, no se observa una relación lineal significativa entre los ingresos anuales y la puntuación de gasto, ni tampoco entre la edad e ingresos, indicando que estas variables tienen un impacto mínimo en el comportamiento de gasto dentro de esta muestra




Figura 3 : Gráfico de correlaciones entre variables

SELECCIÓN Y EVALUACIÓN DE MODELOS

En este análisis exploratorio, se implementaron dos algoritmos de clustering distintos: K-means y DBSCAN. El objetivo fue identificar grupos o segmentos de clientes con características similares, aprovechando las fortalezas de cada método; K-means para encontrar clústeres basados en distancias euclidianas y DBSCAN para descubrir agrupaciones no convexas y detectar outliers.

Para determinar el número óptimo de clústeres en el algoritmo K-means, se aplicó el método del codo. Este proceso involucró ejecutar el algoritmo con diferentes valores de 'k' y evaluar la suma de cuadrados dentro del clúster. Al analizar 'k', se identificó un punto de inflexión significativo cuando $k=5$. Este "codo" en la curva indicó que, con cinco clústeres, se obtenía una reducción sustancial en la varianza interna del modelo, justificando así la selección de $k=5$ como el valor óptimo para el algoritmo K-means en este análisis.




Figura 4 : Curva de elbow para estimar el numero de clusters a usar en k-means

En la aplicación del algoritmo DBSCAN, se determinó un valor de epsilon (eps) de 0.5 como parámetro clave para definir el radio de vecindad alrededor de cada punto. Este valor fue seleccionado tras una evaluación preliminar de la densidad de los datos, buscando un equilibrio entre la capacidad del algoritmo para identificar clústeres densos y evitar la creación de clústeres espurios debido a ruido o puntos aislados. Para facilitar la interpretación y visualización de los resultados del algoritmo K-means en un espacio bidimensional, se aplicó el análisis de componentes principales (PCA). PCA permitió reducir la dimensionalidad de los datos originales, combinando las variables numéricas en un conjunto más pequeño de componentes principales que capturan la mayor parte de la varianza.




Figura 5 : Mapas de dispersión coloreados por cluster, se uso PCA para mejorar la visualización

El gráfico PCA, muestra que el modelo K-means aún produce clústeres relativamente separados, aunque con cierta superposición, lo que sugiere una posible dificultad para distinguir completamente algunos grupos de clientes. El algoritmo DBSCAN, por otro lado, continúa identificando un número menor de clústeres más compactos y define claramente un conjunto de outliers como ruido (representados en negro).

Como alternativa a PCA, se exploró t-distributed Stochastic Neighbor Embedding (t-SNE) como método de reducción de dimensionalidad con el objetivo de mejorar la visualización de los datos. Mientras que PCA busca preservar las distancias originales en un espacio de menor dimensión, t-SNE se enfoca en mantener la estructura local de los datos, agrupando puntos similares cercanos entre sí y separando grupos distintos, lo cual puede revelar patrones más complejos y facilitar la identificación de clusters o subgrupos que podrían no ser evidentes con PCA.




Figura 6 : Mapas de dispersión coloreados por cluster, se uso T-SNE para mejorar la visualización

Los gráficos obtenidos mediante t-SNE revelan diferencias significativas en la estructura de clusters identificados por KMeans y DBSCAN: mientras que KMeans produce grupos relativamente bien definidos pero potencialmente dispersos, DBSCAN destaca la presencia de outliers y forma clusters más compactos basados en la densidad de los datos.

Para entender los perfiles de clientes dentro de cada cluster identificado, se realizaron mapas de distribución para cada variable relevante. Este análisis permitió visualizar cómo las características individuales (como ingresos, edad, historial de compras, etc.) se distribuyen dentro de cada grupo de clientes definido por KMeans y DBSCAN figura 7.




Figura 7 : Distplot por variable para cada modelo-variable

Para el método k-means se reconocen los siguientes perfiles (Basado en los Gráficos de Densidad):

- **Cluster 0 (Morado):** clientes alrededor de los 30-60 años, ingreso alto, puntaje de gasto bajo.
- **Cluster 1 (Naranja):** clientes alrededor de los 25-35 años, ingreso alto, puntaje de gasto muy alto.
- **Cluster 2 (Verde):** clientes 20-35 años, ingreso bajo, puntaje de gasto moderado.
- **Cluster 3 (Azul):** clientes 40-70 años, ingreso moderado, puntaje de gasto moderado.
- **Cluster 4 (Rojo):** clientes 20-35 años, ingreso moderado, puntaje de gasto moderado.

Para el método DBSCAN se reconocen los siguientes perfiles (Basado en los Gráficos de Densidad):

- **Cluster 0 (Azul):** clientes alrededor de los 20-30 años, ingreso bajo, puntaje de gasto alto.
- **Cluster 1 (Naranja):** clientes alrededor de los 25-40 años, ingreso bajo, puntaje de gasto bajo.
- **Cluster 2 (Verde):** clientes 40-70 años, ingreso medio, puntaje de gasto moderado.
- **Cluster 3 (Rojo):** clientes 20-30 años, ingreso moderado, puntaje de gasto moderado.
- **Cluster 4 (Morado):** clientes 20-35 años, ingreso alto, puntaje de gasto alto.
- **Cluster 5 (Café):** clientes 40-50 años, ingreso alto, puntaje de gasto bajo.

CONCLUSIONES

El análisis comparativo utilizando KMeans y DBSCAN, visualizado a través de t-SNE ha revelado perfiles de clientes significativamente distintos. Mientras que KMeans tiende a agrupar individuos con características similares en clusters más amplios, DBSCAN muestra la capacidad de identificar grupos basados en la densidad de los datos, permite una mejor separación de outliers y segmentos de alto gasto.

La elección entre KMeans y DBSCAN depende intrínsecamente del objetivo específico del análisis y la naturaleza de los datos que se están explorando. KMeans, con su enfoque en minimizar la varianza dentro de los clusters, resulta particularmente útil cuando se busca obtener una visión general de los grupos principales presentes en un conjunto de datos. Sin embargo, su dependencia de la especificación previa del número de clusters puede limitar su capacidad para descubrir patrones más complejos o inesperados. Por otro lado, DBSCAN se distingue por su enfoque basado en la densidad, lo que le permite identificar segmentos más especializados y aquellos con patrones de comportamiento inusuales sin requerir una definición previa del número de grupos.

BIBLIOGRAFÍA

Van der Maaten, F., & Hinton, G. E. (2008). Visualizing high-dimensional data using t-SNE. *Journal of Machine Learning Research*, 9(Nov), 2579–2605.

Jain, A. K., Murty, M. N., & Flynn, P. J. (1999). Data clustering: a review. *ACM Computing Surveys (CSUR)*, 31(3), 262–323.

Ester, M., Kriegel, H. P., Sander, J., & Xu, X. (1996). A density-based clustering algorithm. *KDD: Knowledge Discovery in Data Mining*, 22–31.

Shwetabh123. (2023). *Mall customers*. Kaggle. <https://www.kaggle.com/datasets/shwetabh123/mall-customers>