

Modelos Forecast aplicado a ventas por familia de productos

Sebastián Andrés Ulloa Quezada, Universidad Bernardo O'Higgins

Docente: Enrique Gonzalo Pastene Aceituno

Repositorio Codigo :  https://github.com/sightes/2025_Advance_Models_UBO/tree/main/trabajo_final_ML

RESUMEN

Se desarrolló un sistema de predicción de ventas mensuales desagregadas por familia de productos, basado en modelos de machine learning y técnicas de optimización de hiperparámetros. El enfoque modular permitió construir pipelines que integran preprocesamiento, modelado y evaluación, utilizando algoritmos estadísticos y soluciones como regresión logística, árboles de decisión, random forest y soluciones basadas en redes neuronales. A través de validación cruzada y ajuste de hiperparámetros, se lograron identificar configuraciones por familia, mejorando la capacidad predictiva de cada modelo. Como resultado se generaron modelos capaces de generar un forecast en base a variables macroeconómicas y así estimar la venta por familia en un periodo de 12 meses, integrando además un metodo de selección de variables, basado en la correlación y análisis de colinealidad.

INTRODUCCION

El presente trabajo implementa un sistema de predicción de ventas mensuales desagregadas por familia de productos, utilizando un enfoque modular sustentado en modelos clásicos de machine learning y técnicas de optimización. La arquitectura propuesta integra de manera estructurada las etapas de preprocesamiento, selección de variables, modelado y evaluación, permitiendo una gestión eficiente y replicable del flujo analítico. Se utilizaron algoritmos estadísticos y modelos como regresión logística, árboles de decisión, random forest y redes neuronales, evaluados bajo esquemas de validación cruzada y ajuste sistemático de hiperparámetros. Uno de los principales aportes del sistema fue la implementación de un mecanismo de selección de variables basado en la correlación y la colinealidad, lo que permitió mejorar la estabilidad y relevancia de los modelos por familia. Como resultado, se desarrollaron modelos capaces de generar pronósticos de ventas a 12 meses, utilizando como entrada variables macroeconómicas y series históricas, lo que entrega una herramienta útil para la planificación comercial y el análisis estratégico multicanal.

Objetivo y relevancia del problema

El objetivo de este trabajo es desarrollar un sistema de modelado predictivo capaz de estimar las ventas mensuales a nivel de familia de productos, con un horizonte de predicción de hasta 12 meses. Esta solución busca apoyar la planificación comercial y la toma de decisiones estratégicas mediante pronósticos basados en series históricas y variables macroeconómicas. La metodología se enfoca en la construcción de modelos ajustados por familia, lo que permite capturar dinámicas específicas y diferenciadas dentro del portafolio de productos, mejorando así la precisión del forecast.

El problema es relevante debido a que se centra en la necesidad de contar con herramientas analíticas robustas que permitan anticipar el comportamiento de la demanda en contextos comerciales complejos, caracterizados por múltiples canales de venta, alta variabilidad en el consumo y efectos exógenos provenientes del entorno económico. En este sentido, un sistema de forecasting automatizado y granular no solo mejora la eficiencia operativa sino que también habilita una visión prospectiva más informada para definir precios, promociones y estrategias de posicionamiento. Al centrarse en la desagregación por familia de productos y la integración de variables externas, el sistema propuesto busca ser una solución adaptable, escalable y alineada con las necesidades reales de gestión comercial en escenarios dinámicos y competitivos.

Descripción del dataset

El problema propuesto utiliza información de ventas por familia de productos, características de las familias y variables exógenas macroeconómicas. Estas fuentes fueron integradas para conformar un dataset estructurado que permite realizar predicciones desagregadas y contextualizadas.

La información por familias, venta contiene información de 26 familias de productos, y su venta a lo largo de un periodo de 8 años. Además, se cuenta con información exógena la cual consta de 171 variables, que incluyen indicadores económicos globales (como precios de commodities como petróleo, aluminio, oro, etc.), índices bursátiles (Nasdaq, S&P 500), indicadores locales como el IAC (Índice de Actividad Comercial) por canal, turismo, número de partidos y datos climáticos. Este conjunto de variables busca capturar factores externos que puedan incidir en la dinámica de ventas de cada familia. Además, la periodicidad mensual y la disponibilidad de múltiples años de datos permiten entrenar modelos con suficiente profundidad histórica para proyectar escenarios futuros con un horizonte de 12 meses.

Acotación del problema

Dado que realizar un análisis por cada una de las 26 familias, resultaría exhaustivo, se seleccionaron las 4 familias que mostraban comportamientos característicos y diferentes de cada tipo de serie de tiempo. Estas familias fueron, madera y tableros, obra gruesa, temporada y aire libre. Sus series de tiempo pueden observarse en la figura 1.




Figura 1 : Gráfico ejemplo series de tiempo analizadas en el trabajo

Las series de tiempo correspondientes a las distintas familias de productos presentan comportamientos claramente diferenciados en términos de estacionalidad, tendencia y respuesta a eventos exógenos como la pandemia. Por ejemplo, la familia “TEMPORADA” muestra una estacionalidad marcada, con picos concentrados a fines de cada año, lo cual sugiere una alta dependencia de ciclos comerciales como verano o festividades. En contraste, series como “OBRA GRUESA” y “MADERA Y TABLEROS”

exhiben patrones más estables, con variaciones suaves y transiciones progresivas, aunque ambas evidencian un cambio estructural en 2020 asociado a la disrupción generada por la pandemia. Este efecto se manifiesta en un quiebre abrupto de tendencia y cambios en la volatilidad de las ventas. Por otro lado, la familia “AIRE LIBRE” combina estacionalidad con una recuperación sostenida post-pandemia, mostrando un patrón cíclico de repunte anual. Es en base a estas diferencias que los análisis y entrenamientos se generaron por separados dado que las características que influyen en cada serie de tiempo son distintas.

Preparación de características

Durante la etapa de preparación de características, se aplicaron transformaciones orientadas a asegurar la calidad y coherencia de las variables predictoras utilizadas en los modelos. En primer lugar, se integraron diversas fuentes de datos exógenos y se alinearon temporalmente con las series de ventas por familia (esto se realizó mediante un ajuste de lags), utilizando la fecha como clave principal. Para abordar la presencia de valores nulos en las variables numéricas, se aplicó un método de imputación basado en propagación hacia adelante (ffill), que consiste en rellenar cada valor ausente con el último valor válido anterior. Esta técnica es adecuada para series temporales donde se asume cierta persistencia en la dinámica de las variables. Adicionalmente, se estandarizó el formato de fechas, se verificó la consistencia de los índices temporales y se descartaron observaciones incompletas en los extremos de la serie cuando correspondía. El resultado fue una matriz de diseño sin valores faltantes, con variables alineadas y listas para su uso en pipelines de modelado y validación cruzada.

FUNDAMENTACIÓN TEORICA

Se utilizaron 11 modelos distintos para abordar el problema de predicción de series de tiempo, abarcando enfoques clásicos, estadísticos y de machine learning, incluyendo Prophet, Silverkite, Holt-Winters (HW), SARIMAX, Random Forest, Regresión con ElasticNet y árboles, así como arquitecturas neuronales modernas como MLP, LSTM, GRU y Transformers. Esta diversidad permitió comparar el rendimiento entre técnicas lineales, no lineales y basadas en deep learning. A continuación un breve detalle de cada uno de ellos:

- A. **Prophet:** modelo desarrollado por Facebook para la predicción de series temporales, especialmente útil cuando existen componentes estacionales marcados y efectos asociados a días festivos. Está diseñado para funcionar bien incluso con datos históricos irregulares o con valores faltantes, ya que incorpora automáticamente puntos de cambio (changepoints) en la tendencia y permite modelar múltiples estacionalidades. Su enfoque aditivo descompone la serie en tres componentes principales: tendencia (modelada con funciones lineales o logísticas con detección automática de rupturas), estacionalidad (representada mediante series de Fourier) y efectos de eventos especiales como feriados. Además, permite la inclusión de regresores externos y una interpretación clara de cada componente. Prophet puede ajustarse mediante estimación bayesiana utilizando Stan o, alternativamente, mediante métodos deterministas más rápidos, lo que lo convierte en una herramienta flexible, interpretable y de rápida implementación para aplicaciones en entornos de negocio.
- B. **Silverkite:** modelo de series de tiempo desarrollado por LinkedIn como parte de la librería Greykite, diseñado para ofrecer predicciones precisas, rápidas e interpretables en contextos empresariales. Se basa en una regresión lineal regularizada (Ridge) con generación automática de features temporales, incluyendo estacionalidades diarias, semanales, anuales, interacciones, tendencias polinómicas y efectos de días festivos. La estacionalidad se modela con términos armónicos (series de Fourier) y factores categóricos, permitiendo capturar patrones complejos sin requerir estructuras recurrentes o redes neuronales. Silverkite está optimizado para escalabilidad y velocidad, soporta múltiples series en paralelo y permite el uso de regresores externos, intervalos de confianza y detección automática de anomalías. Es especialmente útil cuando se necesita interpretar el aporte de cada variable en la predicción y obtener resultados robustos en ciclos de modelado rápidos.

- C. **Holt-Winters:** también conocido como suavizamiento exponencial triple, es un modelo clásico de series de tiempo que extiende el suavizamiento exponencial simple al incorporar componentes de tendencia y estacionalidad. Funciona mediante la actualización recursiva de tres ecuaciones: nivel, tendencia y estacionalidad, usando coeficientes de suavizamiento α , β y γ . Puede manejar estacionalidades aditivas o multiplicativas, lo que lo hace adecuado para datos con patrones estacionales regulares. Holt-Winters no requiere variables exógenas ni supuestos de estacionariedad, y es especialmente útil para pronósticos de corto plazo en series con estructura estacional estable.
- D. **Sarimax** es una extensión del modelo ARIMA que incorpora componentes estacionales y variables exógenas. Combina autoregresión (AR), integración (I) y medias móviles (MA), junto con sus contrapartes estacionales (SAR, SI, SMA), lo que le permite capturar patrones cíclicos complejos, tendencias y correlaciones temporales en la serie. Además, permite incluir regresores externos (exógenos) para explicar variaciones adicionales en la variable dependiente. SARIMAX requiere que la serie sea estacionaria o se vuelva estacionaria mediante diferenciación. Su estimación se realiza generalmente por máxima verosimilitud, y ofrece resultados interpretables con soporte para pronósticos puntuales, intervalos de confianza y diagnóstico de residuos.
- E. **Random Forest** modelo de machine learning basado en el ensamblado de múltiples árboles de decisión entrenados sobre subconjuntos aleatorios del conjunto de datos y de las variables. En el contexto de series de tiempo, se adapta generando características como rezagos (lags), diferencias y variables estacionales, ya que no modela la dependencia temporal de forma nativa. Cada árbol contribuye con una predicción y el resultado final se obtiene promediando (regresión) o votando (clasificación) entre todos los árboles. Este enfoque reduce el sobreajuste y mejora la generalización. Random Forest es robusto a ruido, captura interacciones no lineales y no requiere supuestos de estacionariedad, pero su interpretabilidad es menor comparado con modelos estadísticos. Además, no extrapola bien fuera del rango de entrenamiento, por lo que se recomienda para horizontes de corto plazo o series densamente muestreadas.
- F. **ElasticNet** modelo lineal de regresión regularizada que combina las penalizaciones de Ridge (L2) y Lasso (L1) en una sola función de costo. Esta combinación permite manejar problemas de multicolinealidad (como Ridge) y realizar selección de variables (como Lasso), lo que lo hace especialmente útil en contextos con muchas variables explicativas, algunas de las cuales pueden ser irrelevantes o altamente correlacionadas. En series de tiempo, ElasticNet se aplica sobre matrices de diseño generadas a partir de transformaciones como lags, medias móviles, estacionalidades y variables externas. La función objetivo minimiza el error cuadrático más una penalización ponderada por el hiperparámetro α , que controla la magnitud total de la regularización, y $l1_ratio$, que define el equilibrio entre L1 y L2. Es un modelo rápido, interpretable y efectivo cuando se desea linealidad con control de complejidad y ruido.
- G. **Arboles de regresión:** son modelos supervisados que dividen iterativamente el espacio de las variables predictoras en regiones homogéneas respecto a una variable continua objetivo. Utilizan reglas de decisión basadas en umbrales que minimizan el error cuadrático medio (MSE) en cada partición, generando una estructura jerárquica tipo árbol. Cada nodo representa una condición sobre una variable, y cada hoja entrega una predicción (promedio de los valores de entrenamiento en esa región). Son fáciles de interpretar, manejan relaciones no lineales y no requieren escalamiento de variables ni supuestos de distribución. En series de tiempo, requieren la creación explícita de características temporales como lags o ventanas móviles.

- H. **MLP (Perceptrón Multicapa)** es un tipo de red neuronal feedforward compuesta por una o más capas ocultas de neuronas totalmente conectadas. Cada neurona aplica una transformación lineal seguida de una función de activación no lineal (como ReLU o tanh), permitiendo capturar relaciones complejas y no lineales entre las variables de entrada y la variable objetivo. En series de tiempo, el MLP no modela directamente la secuencia temporal, por lo que se requiere transformar la serie en una matriz de características mediante lags, ventanas deslizantes y variables exógenas. El entrenamiento se realiza mediante retropropagación y optimización con algoritmos como Adam o SGD, utilizando una función de pérdida como el MSE. Aunque su arquitectura es simple comparada con redes recurrentes, el MLP puede ser eficaz en contextos con series estacionarias o transformadas adecuadamente, y ofrece buena capacidad predictiva en horizontes cortos si la estructura de entrada está bien diseñada.
- I. **LSTM (Long Short-Term Memory)** es un tipo de red neuronal recurrente (RNN) diseñada para modelar secuencias y dependencias temporales a largo plazo, superando las limitaciones de las RNN tradicionales al evitar el desvanecimiento o explosión del gradiente. Su arquitectura incluye celdas de memoria y tres compuertas (entrada, olvido y salida) que regulan el flujo de información, permitiendo conservar contextos relevantes a través del tiempo. En series de tiempo, LSTM recibe como entrada secuencias de observaciones pasadas y es capaz de aprender dinámicas temporales complejas sin necesidad de ingeniería extensiva de features como lags manuales. Se entrena mediante retropropagación a través del tiempo y se optimiza con algoritmos como Adam.
- J. **GRU (Gated Recurrent Unit)** es una variante simplificada de las redes LSTM que también está diseñada para capturar dependencias temporales en secuencias, pero con una arquitectura más eficiente. A diferencia de LSTM, GRU combina las funciones de memoria y control en solo dos compuertas: la compuerta de actualización y la compuerta de reinicio, lo que reduce la complejidad computacional y acelera el entrenamiento. GRU conserva el contexto relevante de la serie temporal sin requerir almacenamiento explícito de estado separado, y es capaz de modelar relaciones a largo y corto plazo con buen desempeño. En tareas de predicción de series de tiempo, GRU se alimenta directamente de secuencias de entrada y puede aprender patrones no lineales y dinámicas multiescales sin necesidad de transformar la serie en lags.
- K. **Transformers aplicados a series de tiempo** son una adaptación de la arquitectura originalmente diseñada para procesamiento de lenguaje natural, basada completamente en mecanismos de atención en lugar de recurrencia. Su componente central, la self-attention, permite que el modelo aprenda relaciones entre cualquier par de posiciones en la secuencia, capturando tanto dependencias de corto como de largo plazo de forma paralela y eficiente. Dado que no poseen una estructura secuencial implícita como las RNN, se incorporan positional encodings para preservar el orden temporal de los datos. En tareas de forecasting, los Transformers pueden recibir como entrada secuencias de lags históricos y covariables exógenas, produciendo predicciones multivariadas o multihorizonte.

Existen variantes especializadas como Informer, Autoformer, Temporal Fusion Transformer (TFT) y Lag-Llama, que introducen mejoras para modelar estacionalidades, jerarquías y atención multiescala. Aunque requieren más datos y potencia computacional, los Transformers destacan por su capacidad para manejar entradas de alta dimensionalidad, múltiples series en paralelo y condiciones de ruido estructurado o dinámicas cambiantes, siendo una opción de vanguardia en problemas de series temporales complejas.

METODOLOGIA

Selección de variables

Como parte del proceso de ingeniería de variables, se aplicó un filtro basado en análisis de correlación respecto de la variable objetivo, con el fin de identificar atributos relevantes para la predicción de ventas por familia. Se calculó la correlación entre cada variable exógena y la serie de ventas, seleccionando únicamente aquellas cuyo coeficiente de correlación superaba un umbral de corte absoluto previamente definido (por ejemplo, $|r| > 0.6$ para obra gruesa). Esta etapa permite reducir el número de variables a aquellas con mayor poder explicativo, eliminando aquellas que introducían ruido. Adicionalmente, se implementó la generación de variables rezagadas (lags) para capturar efectos temporales y dinámicas diferidas en el tiempo.




Figura 2 : alineación de las series de tiempo con sus lags para la familia madera y tableros

Las variables seleccionadas se expandieron con rezagos de hasta 3 períodos mensuales, generando así un conjunto enriquecido de predictores que representaban tanto condiciones actuales como inercia temporal. En la tabla 1 podemos observar las variables que mayor correlación tuvieron contra la target para la familia madera y tableros.

Posteriormente, se evaluó la colinealidad entre variables seleccionadas mediante el análisis de correlación cruzada entre predictores. Este procedimiento permitió identificar grupos de variables altamente correlacionadas entre sí ($r > 0.7$), lo que puede afectar la estabilidad y generalización de algunos modelos, especialmente los lineales. En dichos casos, se eliminaron las variables más redundantes o se priorizó la retención de aquellas con mayor correlación individual con la variable objetivo.

TABLA 1 : VARIABLES CON MAYOR CORRELACION TARGET-REGRESORA PARA FAMILIA MADERA Y TABLEROS

variable	lag	Correlacion
IAC_Ferreteria_Minorista	0	0,913
bienes_durables	0	0,889
transferencias_corrientes_netas	2	0,790

variable	lag	Correlacion
csi300_china	4	0,78
Pandemia	4	0,783
hierro_fob	4	0,65

Generación de splits para validación cruzada

Dado el carácter temporal del problema, la validación cruzada se implementó mediante una estrategia específica para series de tiempo. A diferencia de la validación cruzada aleatoria tradicional, este enfoque respeta la secuencia cronológica de los datos, evitando la fuga de información del futuro al pasado. Para ello, se generaron múltiples divisiones (splits) donde cada conjunto de entrenamiento incluía datos anteriores al conjunto de validación, replicando condiciones realistas de predicción futura. De esta forma se puede evaluar de forma el desempeño de los modelos a lo largo del tiempo, especialmente su capacidad de generalización frente a ventanas temporales no vistas durante el entrenamiento. Además, se mantuvo fijo el horizonte de predicción y se utilizaron ventanas deslizantes para capturar distintos ciclos estacionales.

Optimizacion de hiperparametros , OPTUNA

La selección de hiperparámetros óptimos se llevó a cabo mediante el uso de Optuna, una biblioteca de optimización bayesiana que permite explorar de manera eficiente espacios de búsqueda complejos y no lineales. A diferencia de métodos tradicionales como GridSearchCV o RandomSearch, Optuna implementa una estrategia basada en árboles de Parzen.

Para cada familia de productos, se definió una función objetivo que evaluaba el desempeño de los modelos en términos del error absoluto porcentual medio (MAPE) bajo validación cruzada temporal. Optuna realizó múltiples iteraciones ajustando dinámicamente los hiperparámetros, entre ellas profundidad máxima de árboles, tasa de aprendizaje, número de estimadores, regularización, entre otros parametros en función de los resultados obtenidos en cada ensayo. En total, se realizaron 100 trials por modelo, lo que permitió explorar en profundidad el espacio de búsqueda y capturar configuraciones altamente efectivas y adaptadas a las características particulares de cada serie de ventas.

Entrenamiento y test del modelo

Una vez definidos los conjuntos de variables relevantes y seleccionados los hiperparámetros óptimos mediante validación cruzada, se procedió al entrenamiento final de los modelos sobre el conjunto de entrenamiento completo. El objetivo fue capturar la mayor cantidad de información histórica sin comprometer la generalización. Posteriormente, los modelos fueron evaluados sobre un conjunto de prueba separado, correspondiente a los períodos más recientes no utilizados durante el proceso de ajuste.

Model	Mape
RandomForest	0.049595
Prophet	0.054923
Silverkite	0.060351
RegresionTree	0.064060
ElasticNet	0.069807
GRU	0.085391
LSTM	0.097463
HW	0.100859
SARIMAX	0.105926
Transformer	0.107784
MLP	0.121571




Figura 3 : Resultados comparativos para el modelo de madera y tableros, donde notamos que random Forest, Prophet y Silverkite muestran ser los mejores modelos, sin embargo es posible que para LSTM, GRU y Transformers sea necesario una mejor arquitectura de redes.

RESULTADOS

Los modelos entrenados lograron capturar con éxito las dinámicas particulares de venta por familia de productos, mostrando un desempeño robusto en los conjuntos de prueba. En términos generales, se observaron valores de MAPE inferiores al 15% en las familias con estacionalidad marcada y buena cobertura de datos, como “Obra Gruesa” y “Temporada”. En contraste, algunas categorías más volátiles o con patrones menos definidos presentaron mayor error relativo.

TABLA 2 : RESUMEN RESULTADOS POR FAMILIA

Familia	Random Forest	Silverkite	Prophet	Regression Tree	Elastic Net	MLP	GRU	LSTM	Holtz-Winter	Sarimax	Transformers	Mejor Modelo	Mejor Mape
Madera y Tableros	4,9%	5,4%	6,0%	6,4%	6,9%	12,2%	8,5%	9.74%	10%	10,5%	10,7%	Random Forest	4,9%
Obra Gruesa	7,9%	5,5%	5%	8,4%	8%	7,5%	8,5%	8,4%	7,7%	8,1%	9,8%	Prophet	5%
Pintura y accesorios	4,5%	5,6%	8,6%	4,3%	5,3%	6,6%	8,7%	7,2%	7,7%	6,8%	9,5%	Regression Tree	4,3%
Temporada	19,3%	54,2%	4%	17,1%	39,8%	14,1%	63,9%	4,5%	23,7%	3,3%	16,1%	Sarimax	3,3%
Aire Libre	41,6%	26,3%	23,5%	40,1%	58,5%	46,1%	19,4%	19,3%	20,5%	19,1%	26,7%	Sarimax	19,1%

La evaluación por familia de productos revela que no existe un modelo universalmente superior, sino que el rendimiento varía según las características de cada serie. Modelos estadísticos como SARIMAX y Prophet destacaron por su capacidad para capturar estacionalidades y cambios de tendencia, siendo los más precisos en las familias Temporada, Aire Libre y Obra Gruesa. Por su parte, algoritmos más simples como Random Forest y Regression Tree ofrecieron los mejores resultados en familias con patrones más estables como Madera y Tableros y Pintura y Accesorios, demostrando que modelos no lineales clásicos aún compiten en ciertos contextos.


En contraste, los modelos basados en redes neuronales profundas como GRU, LSTM y MLP no lograron liderar en ninguna familia, lo que sugiere que sus ventajas no se manifiestan plenamente en este caso, posiblemente por limitaciones de datos, bajo beneficio de capturar dependencias de largo plazo o falta de mejora en la arquitectura que las conforman.

Asimismo, Silverkite mostró resultados inconsistentes, con errores elevados en series como Temporada, indicando que es posible que al ser estacional, y una métrica media, la varianza de la serie este provocando que el error se eleve artificialmente, dado que existen meses donde la venta es muy baja o bien cero.

En la sección anterior ya revisamos las variables para la familia madera y tableros, los resultados de la selección de las restantes familias es la siguiente:

Obra gruesa :


variable	lag	correlación
imacec_no_minero	0	0.71
consumo_hogar_ipsfl	0	0.65
bienos_no_durables	0	0.60



Para la familia Obra Gruesa, los features mas correlacionados sugieren que el comportamiento económico general y el consumo interno están estrechamente ligados a la demanda de esta categoría.

Pintura y Accesorios:


variable	lag	correlación
bienos_no_durables	0	0.77
consumo_final_efectivo	0	0.74
consumo_hogar_ipsfl	0	0.74
imacec	0	0.70
colocaciones_comerciales	0	0.70
colocacione_vivienda	0	0.67
subsidios_donaciones	1	0.64
Norte_wspd	2	0.61
hierro_fob	4	0.60



En la familia Pintura y Accesorios, se observa una fuerte correlación contemporánea entre la serie de ventas y múltiples variables macroeconómicas. También resaltan variables financieras como las colocaciones comerciales y de vivienda, lo cual sugiere que este segmento es sensible tanto a la liquidez como al acceso a crédito en el mercado. En los gráficos de predicción, podemos notar que el modelo Regression Tree logra un ajuste muy preciso con respecto al histórico reciente, lo cual se alinea con su elección como el mejor modelo para esta familia. Sin embargo otros modelos candidatos como LSTM o Prophet capturan razonablemente bien la estacionalidad, presentan mayor desviación en momentos clave.

Temporada :


variable	lag	correlación
Primavera	1	0.82
Fiestas_patrias	2	0.73
Navidad	0	0.45
IAC_Electricos_y_Hogar	0	0.44
Sur_prcp	4	0.40
colocacione_viv ienda	0	0.67
subsidiros_donac iones	1	0.64
Norte_wspd	2	0.61
hierro_fob	4	0.60



En la familia Temporada, se evidencian patrones altamente estacionales, con picos anuales marcados que coinciden con eventos clave como Primavera y Fiestas Patrias, ambos con desfases positivos, lo que indica que su efecto anticipa las ventas. Otras variables como colocaciones de vivienda y subsidios también muestran correlaciones relevantes, lo que sugiere que el consumo estacional está vinculado tanto a factores climáticos como a dinamismo económico. La mayoría de los modelos subestiman la magnitud de los picos, siendo SARIMAX el que mejor logra capturar la forma y magnitud de los eventos estacionales. Modelos más complejos como Transformers o GRU tienden a suavizar la serie, lo que reduce su capacidad de replicar adecuadamente los aumentos abruptos, reflejando la ventaja de modelos estadísticos cuando las estacionalidades son dominantes y recurrentes.

Aire Libre :

variable	lag	correlación
Primavera	2	0.81
Fiestas_patrias	3	0.62
IAC_Electricos_y_Hogar	0	0.59
Sur_prcp	4	0.51
bienos_no_durab les	0	0.43
Norte_wspd	1	0.42
cobre_fob	1	0.40



En la familia Aire Libre, la estacionalidad es un factor importante, destacando la variable Primavera, lo que sugiere un fuerte componente anticipado en la demanda. También influyen eventos como Fiestas Patrias y condiciones climáticas como la precipitación en el sur y la velocidad del viento en el norte, lo que refleja una relación directa entre factores ambientales y la variabilidad de ventas en esta categoría. Los gráficos muestran que si bien todos los modelos capturan la forma general de los picos estacionales, la magnitud de las predicciones varía considerablemente. Modelos como Regression Tree y MLP tienden a subestimar los niveles de recuperación tras los valles estacionales, evidenciando su menor capacidad para adaptarse a cambios rápidos y recurrentes.

CONCLUSIONES

La selección de modelos debe ser específica por familia: No existe un único modelo dominante para todas las categorías. Modelos estadísticos como SARIMAX y Prophet se destacaron en familias con alta estacionalidad o sensibilidad macroeconómica, mientras que métodos clásicos como Regression Tree y Random Forest fueron más efectivos en series con patrones más estables o menos ruidosos.

El uso de variables exógenas mejora el desempeño predictivo: En todas las familias, se identificaron correlaciones significativas con variables económicas, climáticas o estacionales. Su incorporación mejora la precisión, especialmente en modelos como SARIMAX o Prophet, que integran regresores externos de forma nativa.

Los modelos de deep learning no fueron los más efectivos: A pesar de su capacidad para capturar no linealidades complejas, modelos como LSTM, GRU y MLP no lideraron en ninguna familia, posiblemente debido a limitaciones de datos, tamaño de muestra o falta de estructura secuencial profunda en las series.

Las familias con fuerte estacionalidad se benefician de modelos que la modelan explícitamente: Categorías como Temporada y Aire Libre mostraron picos de demanda altamente predecibles ligados a eventos y estaciones, donde modelos como SARIMAX sobresalieron gracias a su capacidad para capturar componentes estacionales y su interpretación estructurada.

BIBLIOGRAFÍA

Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice* (2nd ed.).

Seabold, S., & Perktold, J. (2010). *Statsmodels: Econometric and statistical modeling with Python*. Proceedings of the 9th Python in Science Conference. <https://www.statsmodels.org/>

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>

Zou, H., & Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 67(2), 301–320. <https://doi.org/10.1111/j.1467-9868.2005.00503.x>

Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). *Classification and regression trees*. Belmont, CA: Wadsworth International Group.

Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (2nd ed.). O'Reilly Media.

Brownlee, J. (2018). Deep Learning for Time Series Forecasting: Predict the Future with MLPs, CNNs and LSTMs in Python. Machine Learning Mastery.

Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder–decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078*. <https://arxiv.org/abs/1406.1078>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30. <https://arxiv.org/abs/1706.03762>